Βαθμονόμηση δύο σταδίων του NCDawareRank — Τεχνική τεκμηρίωση

Ιωάννης Κωνσταντέλλος
Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστήμιο Πατρών

Οκτώβριος 2026

Περιεχόμενα

1. Σκοπός του εγγράφου **2**
1.1 Το ερευνητικό ερώτημα σε μία παράγραφο . . . 2
1.2 Βασικά αποτελέσματα (όλοι οι αριθμοί αναπαράγονται από τον κώδικα) . . . 2

2. Δομή του αποθετηρίου **3**

3. Αρχιτεκτονική λογισμικού **4**
3.1 Ροή δεδομένων . . . 4
3.2 Σχεδιαστικές αρχές . . . 5

4. Περιβάλλον **5**

5. Περιγραφή ανά άρθρωμα **5**
5.1 Κοινός συμβολισμός . . . 5
5.2 `ncd_calibration_lib.py` (κεντρική βιβλιοθήκη) . . . 6
5.2a `ncd_autotune.py` (πρακτικό εργαλείο ενός στιγμιότυπου) . . . 7
5.3 `decode_cnr2000.py` και `prepare_real_graphs.py` . . . 8
5.4 `run_experiments.py` (οδηγός πειραμάτων) . . . 8
5.5 Σενάρια ανάλυσης του Σταδίου 1 . . . 9
5.6 Σενάρια ανάλυσης του Σταδίου 2 . . . 9
5.7 `generate_figures.py` και `fig_lang.py` . . . 10
5.8 `make_paper_assets.py` . . . 11
5.9 Έλεγχοι μονάδας . . . 11

6. Πολυπλοκότητα και μηχανισμοί των επιλυτών **11**
6.1 Κατασκευή των τελεστών σε χρόνο και χώρο $O(m+n)$ . . . 11
6.2 Τα στατιστικά βαθμονόμησης σε $O(m+n)$ (Πρόταση 5 της εργασίας) . . . 12
6.3 Η μέθοδος των δυνάμεων . . . 12
6.4 Η σάρωση του α με σειρά Neumann . . . 12
6.5 Γιατί έχουν σημασία οι ακριβείς ισοβαθμίες . . . 13
6.6 Λοιπά κόστη . . . 13

7. Αλήθειες αναφοράς **13**

8. Σύνολα, σπόροι και διαταραχές **14**

9. Στατιστική μεθοδολογία **14**

10. Έξοδοι: αρχεία, σχήματα και πίνακες **15**
10.1 Αρχεία αποτελεσμάτων . . . 15

10.2 Σχήματα 15
10.3 Πίνακες της εργασίας 16

11. Αναπαραγωγή βήμα προς βήμα **17**

12. Περιορισμοί που πρέπει να λαμβάνονται υπόψη κατά την παράθεση των αποτελεσμάτων **18**

13. Αντιστοίχιση με κεφάλαια της διπλωματικής **18**

1. Σκοπός του εγγράφου

Ο οδηγός αυτός τεκμηριώνει το λογισμικό, τα δεδομένα, τα πειράματα και τα αποτελέσματα στα οποία στηρίζεται το κείμενο *Βαθμονόμηση δύο σταδίων της διασπάσιμης κατάταξης ιστοσελίδων: πιθανότητα διαφυγής από το μπλοκ, απόκλιση εισερχόμενων μεταβάσεων και η αγκύρωση της βέλτιστης απόσβεσης* (`paper/paper_gr.pdf`, αγγλική εκδοχή `paper/paper_en.pdf`). Είναι γραμμένος ώστε κάθε τμήμα του να μπορεί να ενσωματωθεί σε διπλωματική εργασία: η Ενότητα 3 περιγράφει την αρχιτεκτονική, η Ενότητα 5 εξετάζει κάθε άρθρωμα, η Ενότητα 6 αποδεικνύει τους ισχυρισμούς πολυπλοκότητας και εξηγεί τον επιλυτή σειράς Neumann, οι Ενότητες 7–9 ορίζουν τις αλήθειες αναφοράς, τα σύνολα και τη στατιστική μεθοδολογία, η Ενότητα 10 εξηγεί κάθε αρχείο εξόδου, σχήμα και πίνακα, και η Ενότητα 11 δίνει οδηγίες αναπαραγωγής βήμα προς βήμα.

1.1 Το ερευνητικό ερώτημα σε μία παράγραφο

Το NCDawareRank (Nikolakopoulos και Garofalakis, WSDM 2013, στο εξής [NG13]) κατατάσσει τις σελίδες του Ιστού με την αλυσίδα Markov $P = \eta H + \mu M + (1-\eta-\mu)E$, όπου H είναι ο πίνακας υπερσυνδέσμων, M ο πίνακας διεπίπεδης εγγύτητας που ορίζεται πάνω σε NCD μπλοκ (για παράδειγμα, ιστοτόπους) και $E = ev^\top$ ένας πίνακας τηλεμεταφοράς ισοκατανεμημένης ανά μπλοκ. Η γραφή $\eta = (1-r)\alpha$ και $\mu = r\alpha$ διαχωρίζει τον *λόγο ανάμειξης* r από τη *συνολική απόσβεση* α. Η μελέτη ελέγχει μια βαθμονόμηση δύο σταδίων μηδενικού κόστους:

- Το **Στάδιο 1** σταθεροποιεί το $\alpha_0 = 0.85$ και επιλέγει $r = f(\bar{P}^{(M)}_{\text{esc}})$ από τη μέση πιθανότητα διαφυγής από το μπλοκ $\bar{P}^{(M)}_{\text{esc}} = \frac{1}{n}\sum_u k_u/(k_u+1)$, όπου k_u είναι το πλήθος των διακριτών εξωτερικών μπλοκ στα οποία δείχνει η σελίδα u.
- Το **Στάδιο 2** διατηρεί αυτό το r και επιλέγει $\alpha = g(h)$ από τη μέση απόλυτη απόκλιση $h = \frac{1}{n}\sum_v |1-\Sigma_{\text{in}}(v;r)|$ των αθροισμάτων στηλών του $Z_r = (1-r)H + rM$ από τη μονάδα.

1.2 Βασικά αποτελέσματα (όλοι οι αριθμοί αναπαράγονται από τον κώδικα)

Στοιχείο	Αποτέλεσμα
Κλειδωμένος κανόνας Σταδίου 1	$r = \text{clip}(0.242 - 0.143\,\bar{P},\ 0.01,\ 0.99)$· καλύτερη σταθερά $r = 0.18$
Κλειδωμένος κανόνας Σταδίου 2	ο βέλτιστος ως προς τ κανόνας στο h καταλήγει στη σταθερά $\alpha = 0.810$ (0.930 υπό την NCD95)
Δύο στάδια έναντι κανονικής ρύθμισης $(r, \alpha) = (0.118, 0.85)$	`test` $+0.0110$ στο τ του Kendall (31/32 γράφοι, $p = 9.3 \times 10^{-10}$)· `scale` $+0.0102$· `topo` $+0.0036$· `real` $+0.0017$ ($p = 0.812$, μη σημαντικό)
Δύο στάδια έναντι της ρύθμισης κατάταξης του [NG13] $(r, \alpha) = (0.105, 0.95)$, αλήθεια NCD	`test` $+0.0743$ (32/32 γράφοι, $p = 4.7 \times 10^{-10}$)· `scale` $+0.0756$ (12/12)· `topo` $+0.0515$ (24/24)· `real` $+0.0848$ (5/5, $p = 0.0625$, το ακριβές κατώτατο όριο για $n = 5$). **Επιφύλαξη άγκυρας:** η αλήθεια NCD ορίζεται η ίδια στην απόσβεση 0.85, άρα ο αριθμός αυτός μετρά κυρίως την ασυμφωνία άγκυρας της αναφοράς και δεν αποτελεί ένδειξη για τη μέθοδο (Πίνακας `tab:mismatch`, `V2_WP0_mismatch_table.md`).

Στοιχείο	Αποτέλεσμα
Σταθερές με αντιστοίχιση άγκυρας	Για αναφορά στο 0.85 χρησιμοποιείται $\alpha = 0.81$, ενώ για αναφορά στο 0.95 χρησιμοποιείται $\alpha = 0.93$. Η απόφαση για την απόσβεση αναφοράς είναι μεθοδολογική, όχι ιδιότητα του γράφου. Κέρδη με αντιστοίχιση στο `test`: $+0.0110$ (31/32, $p = 9.3 \times 10^{-10}$) υπό NCD έναντι $(0.118, 0.85)$, αλλά μόνο $+0.0011$ (19/32, $p = 0.062$, ισοπαλία) υπό NCD95 έναντι $(0.105, 0.95)$· στο `real` της NCD95 η αντιστοιχισμένη διαφορά είναι -0.0006. Με τον κανόνα r του Σταδίου 1 στη θέση του 0.105 (ο συνδυασμός που χρησιμοποιεί το `ncd_autotune.py` στην άγκυρα 0.95) το κέρδος του 0.93 έναντι του $(0.105, 0.95)$ είναι $+0.0089$ (30/32, $p = 5.0 \times 10^{-7}$) στο `test`, $+0.0062$ στο `scale`, $+0.0034$ στο `topo` και -0.0025 στο `real`· η βέλτιστη σταθερά βαθμονόμησης γι' αυτόν τον συνδυασμό είναι 0.920 ($+0.0002$ στο τ έναντι του 0.93). Οι μη αντιστοιχισμένοι συνδυασμοί μεταβάλλουν το τ κατά -0.03 έως -0.04 στο `test` (Πίνακας `tab:mismatch`).
Προβλεπτική αξία των $\bar{P}$, h, h_v	καμία εκτός δείγματος· το h μειώνεται υπό αφαίρεση συνδέσμων και αυξάνεται υπό τη διαταραχή νεοεισαχθεισών σελίδων, ενώ το α^* μειώνεται και στις δύο
Μη μονότονη g και g χωρίς την επίδραση των κρεμάμενων (αδιέξοδων) σελίδων (dangling nodes)	κανένας από 127 εφαρμόσιμους κανόνες (τέντες, τετραγωνική, γκαουσιανό εξόγκωμα, κλιμακωτές συναρτήσεις, splines στα h, h_v, h_{raw}, δ, ζ· κανόνες δύο μεταβλητών $g(h, \delta)$, $g(h, \zeta)$) δεν περνά τον προκαθορισμένο έλεγχο εκτός δείγματος· η βέλτιστη ως προς τ τέντα στο h μεταβάλλει το τ κατά -0.0001 εκτός δείγματος· με γνωστό το h_0 του αδιατάρακτου γράφου (μη παρατηρήσιμο) μια τέντα στο $h - h_0$ κερδίζει $+0.0018$ στη CV και $+0.0006$ εκτός δείγματος, οπότε το $\alpha = 0.810$ παραμένει κλειδωμένο
Αγκύρωση	η βέλτιστη α^* ισούται με την απόσβεση της κατάταξης αναφοράς μείον μια έκπτωση θορύβου 0.03–0.06· κλίση δόσης–απόκρισης 0.950
Θεωρία	$h = \|u^\top Z_r - u^\top\|_1$, $h_v = \|v^\top Z_r - v^\top\|_1 = \|\mathrm{d}\pi/\mathrm{d}\alpha\|_{\alpha=0}$ και $\|\pi(\alpha) - v\|_1 \leq \frac{\alpha}{1-\alpha} h_v$
Σύγκλιση	η μείωση του α από 0.85 σε 0.81 εξοικονομεί 14.7% των επαναλήψεων της μεθόδου των δυνάμεων στο `test` (εκ των προτέρων εκτίμηση 22.9%)

2. Δομή του αποθετηρίου

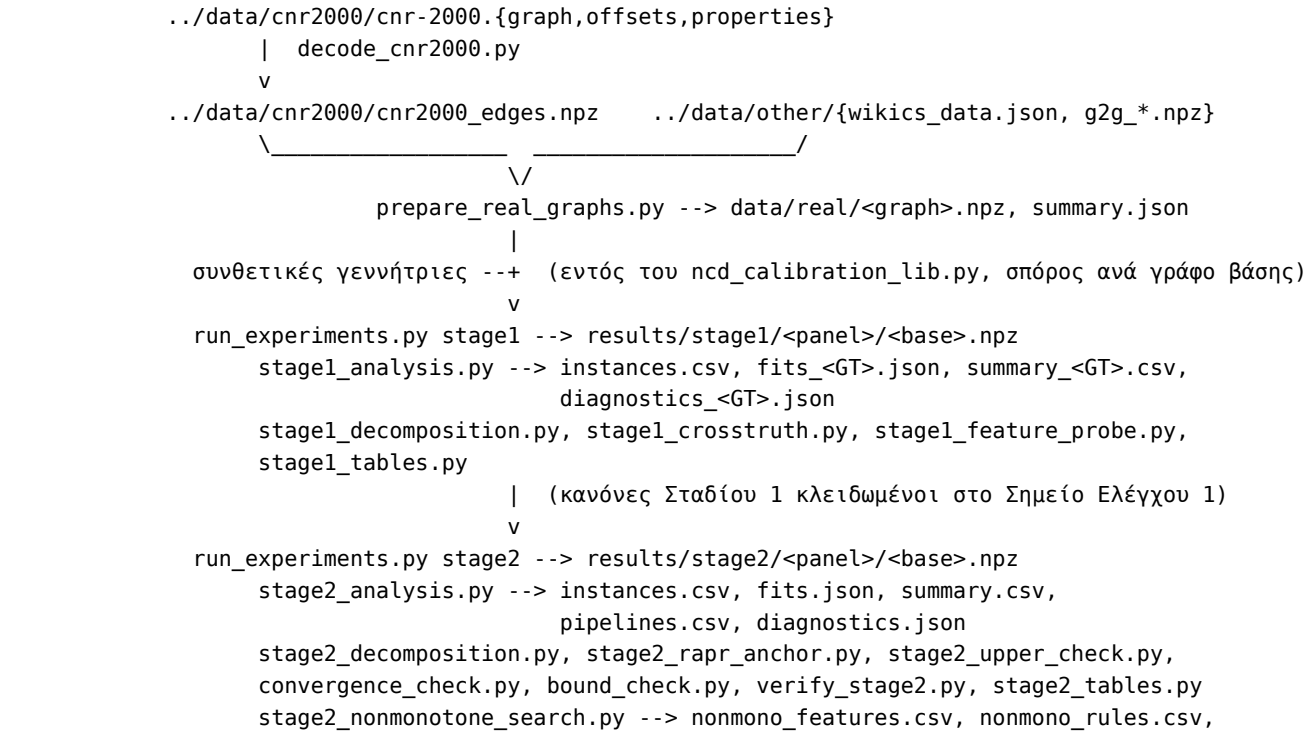
```
ncdcal/
  ncd_calibration_lib.py    κεντρική βιβλιοθήκη: τελεστές, επιλυτές, στατιστικά,
                            διαταραχές, γεννήτριες, μετρικές κατάταξης, σαρώσεις Σταδίου 2
  decode_cnr2000.py         αρχεία BVGraph του cnr-2000 -> απλή λίστα τόξων
  prepare_real_graphs.py    κατασκευάζει τα data/real/*.npz και data/real/summary.json
  run_experiments.py        οδηγός πειραμάτων: stage1 | stage2 (πολυεπεξεργασία)
  run_stage1_all.sh         εκτελεί διαδοχικά όλα τα σύνολα του Σταδίου 1
  run_stage2_all.sh         εκτελεί διαδοχικά όλα τα σύνολα του Σταδίου 2
  stage1_analysis.py        βέλτιστο r*, υποψήφιοι κανόνες f, αξιολόγηση, διαγνωστικά
  stage1_decomposition.py   αποσύνθεση διασποράς του r*
  stage1_feature_probe.py   διαγνωστικό: στατιστικά πληροφοριακότητας των μπλοκ
  stage1_crosstruth.py      κανόνες μιας αλήθειας αξιολογημένοι υπό τις άλλες
  stage1_tables.py          πίνακες markdown του Σημείου Ελέγχου 1
  stage2_analysis.py        βέλτιστο alpha*, υποψήφιοι κανόνες g, διαδικασίες, διαγνωστικά
  stage2_decomposition.py   αποσύνθεση διασποράς και άγκυρες του alpha*
  stage2_rapr_anchor.py     έλεγχος δόσης-απόκρισης με αναφορές Random-alpha
  stage2_upper_check.py     έλεγχος λογοκρισίας στην κορυφή του πλέγματος (αλήθεια Q)
```

```
stage2_tables.py          πίνακες markdown του Σημείου Ελέγχου 2
stage2_nonmonotone_search.py
                          μη μονότονοι κανόνες και κανόνες χωρίς την επίδραση των
                          κρεμάμενων σελίδων g(h), g(h, delta), g(h, zeta) έναντι της
                          κλειδωμένης σταθεράς (Ενότητα 8.2 της εργασίας)
build_papers.sh           αναπαράγει τα στοιχεία και μεταγλωττίζει τα δύο κείμενα
build_docs.sh             κατασκευάζει τα PDF των δύο εγγράφων τεκμηρίωσης
verify_stage2.py          ανεξάρτητος επανυπολογισμός των βασικών αριθμών
convergence_check.py      επαναλήψεις της μεθόδου των δυνάμεων πριν/μετά την έκπτωση
bound_check.py            αριθμητικός έλεγχος του φράγματος μετατόπισης
generate_figures.py       τα έξι σχήματα της δημοσίευσης (EN και GR)
fig_lang.py               επίπεδο ελληνικής μετάφρασης των σχημάτων
make_paper_assets.py      αριθμοί (μακροεντολές) και πίνακες των δύο κειμένων
tests/test_lib.py         έλεγχοι μονάδας της βιβλιοθήκης (τμήματα Σταδίου 1)
tests/test_stage2.py      έλεγχοι μονάδας των προσθηκών του Σταδίου 2
tests/test_nonmono.py     έλεγχοι μονάδας του stage2_nonmonotone_search.py
data/real/                έτοιμοι πραγματικοί γράφοι (npz) και summary.json
results/stage1/           πρωτογενή αρχεία ανά γράφο και έξοδοι ανάλυσης Σταδίου 1
results/stage2/           πρωτογενή αρχεία ανά γράφο και έξοδοι ανάλυσης Σταδίου 2
results/paper_numbers.json  κάθε αριθμός που αναφέρεται στα κείμενα
figures/, figures_gr/     σχήματα δημοσίευσης (PDF + PNG), αγγλικά / ελληνικά
logs/                     καταγραφές κονσόλας των εκτελέσεων
paper/                    paper_en.tex/.pdf, paper_gr.tex/.pdf, generated/
DOCUMENTATION_EN.md/.pdf, DOCUMENTATION_GR.md/.pdf
METHOD_DISCLOSURE_EN_GR.md/.txt   δήλωση μεθόδου (EN και GR), εκτός των κειμένων
```

Τα πρωτογενή αρχεία λήψης (αρχεία BVGraph του cnr-2000, το JSON του WikiCS και τα αρχεία CitationFull) βρίσκονται ένα επίπεδο υψηλότερα, στο `../data/`, επειδή αποτελούν εισόδους και όχι προϊόντα της ροής επεξεργασίας.

3. Αρχιτεκτονική λογισμικού

3.1 Ροή δεδομένων



```
                                        nonmono_summary.json
                          v
generate_figures.py (+ fig_lang.py) --> figures/, figures_gr/
make_paper_assets.py --> paper/generated/{macros.tex, en/, gr/},
                           results/paper_numbers.json
xelatex paper_en.tex / paper_gr.tex --> paper_en.pdf / paper_gr.pdf
```

3.2 Σχεδιαστικές αρχές

1. **Μία βιβλιοθήκη, λεπτά σενάρια.** Όλα τα μαθηματικά βρίσκονται στο `ncd_calibration_lib.py`. Τα σενάρια οργανώνουν τις εκτελέσεις, προσαρμόζουν κανόνες και γράφουν εξόδους· δεν περιέχουν ανεξάρτητη υλοποίηση της αλυσίδας (μοναδική εξαίρεση το `verify_stage2.py`, που σκόπιμα επαναϋπολογίζει τους βασικούς αριθμούς από τα πρωτογενή αρχεία χωρίς να εισάγει τον κώδικα ανάλυσης).
2. **Αιτιοκρατία.** Κάθε γράφος βάσης έχει τον δικό του σπόρο (Ενότητα 8). Οι διαταραχές του παράγονται από τον ίδιο `numpy.random.Generator`, με σταθερή σειρά, οπότε ο οδηγός του Σταδίου 2 και τα διαγνωστικά σενάρια *αναπαράγουν* ακριβώς τα στιγμιότυπα του Σταδίου 1. Το `stage1_feature_probe.py` ελέγχει την αναπαραγωγή έναντι των αποθηκευμένων γραμμών.
3. **Ο γράφος βάσης είναι η μονάδα επανάληψης.** Τα διαταραγμένα στιγμιότυπα ενός γράφου βάσης μοιράζονται τη δομή του. Κάθε ζευγαρωτός έλεγχος και κάθε διάστημα bootstrap υπολογίζεται πάνω σε μέσες τιμές ανά γράφο, και κάθε διαχωρισμός (βαθμονόμηση/έλεγχος/μεταφορά, πτυχές διασταυρωμένης επικύρωσης) γίνεται ανά γράφο βάσης.
4. **Προσωρινή αποθήκευση και επανεκκίνηση.** Κάθε γράφος βάσης παράγει ένα συμπιεσμένο αρχείο `npz`. Ο οδηγός παρακάμπτει τα αρχεία που υπάρχουν ήδη, οπότε μια διακοπείσα εκτέλεση συνεχίζει από εκεί που σταμάτησε.
5. **Κανένας αριθμός πληκτρολογημένος με το χέρι.** Κάθε αριθμός στα δύο κείμενα είναι μακροεντολή LaTeX και κάθε πίνακας παράγεται αυτόματα, και τα δύο από το `make_paper_assets.py` με βάση τα αρχεία αποτελεσμάτων.
6. **Ακριβή στατιστικά κατάταξης.** Οι επιλυτές χρησιμοποιούν μόνο γινόμενα αραιού πίνακα–διανύσματος και κλιμακώσεις ανεξάρτητες από τα στοιχεία, οπότε δομικά ταυτόσημες σελίδες διατηρούν πανομοιότυπες (bit προς bit) βαθμολογίες και το τ του Kendall βλέπει τις πραγματικές ισοβαθμίες (Ενότητα 6.5).

4. Περιβάλλον

Συστατικό	Έκδοση
Python	3.13
NumPy / SciPy	2.5.3 / 1.18.1
pandas	3.0.5
scikit-learn	1.9.1 (ενίσχυση κλίσης, ridge, ισοτονική παλινδρόμηση, διασταυρωμένη επικύρωση)
matplotlib	3.11.2
webgraph (Python bindings του webgraph-rs)	0.2.0, μόνο για το `decode_cnr2000.py`
XeLaTeX	TeX Live, με `fontspec`, `txfonts`, `babel` (αγγλικά, ελληνικά), γραμματοσειρά FreeSerif
pandoc	για τις εκδοχές PDF αυτής της τεκμηρίωσης

Οι εξαρτήσεις Python εγκαθίστανται με `pip install numpy scipy pandas scikit-learn matplotlib webgraph`. Τα πειράματα εκτελέστηκαν με δύο διεργασίες· το Στάδιο 1 χρειάστηκε περίπου 69 λεπτά και το Στάδιο 2 περίπου 101 λεπτά πραγματικού χρόνου για το πλήρες σύνολο πειραμάτων, με κυρίαρχο κόστος τον μεγαλύτερο πραγματικό γράφο (cnr-2000).

5. Περιγραφή ανά άρθρωμα

5.1 Κοινός συμβολισμός

Σύμβολο	Κώδικας	Σημασία
n, N, m	`ops.n`, `ops.N`, `ops.m`	σελίδες, μπλοκ, τόξα
$\mathcal{G}_u, d_u$	`src`, `dst`, `ops.d_out`	εξερχόμενοι γείτονες και βαθμός εξόδου
$\mathcal{A}_{(u)}$	`ops.block[u]`	μπλοκ της σελίδας u
$N_u = k_u + 1$	`ops.k_ext + 1`	μπλοκ στο σύνολο εγγύτητας $\mathcal{X}_u$
$H^\top$	`ops.HT` (CSR, $n \times n$)	ανάστροφος πίνακας υπερσυνδέσμων χωρίς κρεμάμενες γραμμές
$R^\top$	`ops.RT` (CSR, $N \times n$)	ανάστροφος παράγοντας εγγύτητας μπλοκ, $M = RA$
A	`ops.block` (απεικόνιση δεικτών)	πρόσπτωση σελίδας–μπλοκ, εφαρμόζεται με δεικτοδότηση
v	`ops.v`	τηλεμεταφορά ισοκατανεμημένη ανά μπλοκ, $v_u = 1/(N\lvert\mathcal{A}_{(u)}\rvert)$
r, α	`r`, `alpha`	λόγος ανάμειξης και συνολική απόσβεση, $\eta = (1-r)\alpha$, $\mu = r\alpha$

Οι κρεμάμενες (αδιέξοδες) σελίδες (dangling nodes, $d_u = 0$) έχουν ομοιόμορφες γραμμές $e^\top/n$ στον H. Δεν αποθηκεύονται: κάθε γινόμενο με τον H προσθέτει τον όρο τάξης ένα $(\sum_{u \text{ κρεμάμενη}} x_u)/n$.

5.2 `ncd_calibration_lib.py` (κεντρική βιβλιοθήκη)

Σταθερές. `ALPHA0 = 0.85`· `R_CANONICAL = 0.10/0.85` (ο κανονικός διαχωρισμός $(\eta, \mu) = (0.75, 0.10)$ του [NG13, Πίνακας 2])· `R_GRID = 0.00, 0.01, …, 0.99` (πλέγμα Σταδίου 1)· `ALPHA_GRID` = 0.05, 0.10, …, 0.35 και έπειτα 0.40, 0.41, …, 0.99 (67 τιμές)· οι βέλτιστες παράμετροι αναφοράς (oracle / μαντείο) αναζητούνται μόνο στις τιμές ≥ 0.40 (`ALPHA_ORACLE_MASK`)· `ALPHA_NG13 = 0.95`, `R_NG13 = 0.10/0.95` (η ρύθμιση των πειραμάτων κατάταξης του [NG13, §4]).

1. Δομή γράφου. Η `Graph(n, src, dst, block, name, meta)` περιέχει έναν κατευθυνόμενο γράφο με NCD διαμέριση· η `subgraph_arcs(keep)` επιστρέφει τις ίδιες σελίδες και διαμέριση με ένα υποσύνολο των τόξων. Η `clean_arcs(n, src, dst)` αφαιρεί βρόχους και διπλά τόξα ταξινομώντας ακέραια κλειδιά $u \cdot n + v$.

2. Τελεστές. Η `build_operators(g)` επιστρέφει `NCDOperators` με πεδία `n, N, m, block, block_size, d_out, dangling, HT, RT, k_ext, n_ext_arcs, v`:

- ο `HT` κατασκευάζεται απευθείας σε ανάστροφη μορφή, $H^\top_{vu} = 1/d_u$ για κάθε τόξο $u \to v$·
- τα μη μηδενικά στοιχεία του R είναι τα διακριτά ζεύγη (σελίδα, μπλοκ) που σχηματίζονται από το μπλοκ κάθε σελίδας και τα μπλοκ των εξερχόμενων γειτόνων της· το `N_u` τα μετρά, και $R^\top_{Iu} = 1/(N_u\lvert\mathcal{A}_I\rvert)$·
- $v_u = 1/(N\,\lvert\mathcal{A}_{(u)}\rvert)$.

Η υλοποίηση βρίσκει τα διακριτά ζεύγη με ένα διανυσματοποιημένο `np.unique` σε ακέραια κλειδιά (μια ταξινόμηση κόστους $O(m' \log m')$, με $m' = n+$ τόξα μεταξύ μπλοκ). Η Πρόταση 5 της εργασίας δίνει την κατασκευή των ίδιων ζευγών με πίνακα σημαδιών σε χρόνο $O(\lvert\mathcal{E}\rvert + n)$ (Ενότητα 6.1).

3. Επιλυτής. Η `ncdawarerank(ops, alpha, r, x0=None, tol=1e-10, maxit=20000, teleport=None)` είναι η παραγοντοποιημένη μέθοδος των δυνάμεων του [NG13, Αλγόριθμος 1]:

$$\pi^{(k+1)} = \eta\, \pi^{(k)\top} H + \mu\, (\pi^{(k)\top} R) A + (1-\alpha) v^\top,$$

με αφετηρία το v (ή το `x0`), κανονικοποίηση ώστε το άθροισμα να είναι ένα, και τερματισμό όταν $\|\pi^{(k+1)} - \pi^{(k)}\|_1 <$ `tol`· επιστρέφει `(pi, iterations)`. Η `sweep_r(ops, alpha, r_values)` επιλύει κατά μήκος ενός πλέγματος τιμών του r, ξεκινώντας κάθε επίλυση από την προηγούμενη λύση (Στάδιο 1). Η `dense_P(ops, eta, mu)` κατασκευάζει τους πυκνούς πίνακες μόνο για τους ελέγχους μονάδας.

4. Στατιστικά.

- Η `block_escape(ops)` επιστρέφει την $P^{(M)}_{\text{esc}}(u) = k_u/(k_u+1)$ και τη μέση τιμή της $\bar{P}$.
- Η `incoming_sums(ops)` επιστρέφει το $\Sigma^{(H)}_{\text{in}}(v) = \sum_{u \to v} 1/d_u + n_{\text{d}}/n$ (αθροίσματα γραμμών του `HT` συν τον όρο των κρεμάμενων σελίδων) και το $\Sigma^{(M)}_{\text{in}}(v)$ (αθροίσματα γραμμών του `RT`, αντιγραμμένα από τα μπλοκ στις σελίδες).

- Η `h_statistic(ops, r)` επιστρέφει το $h(r)$ και τη μέση τιμή του Σ_{in} (η οποία πρέπει να ισούται με 1).
- Η `h_statistics(ops, r)` επιστρέφει τα `h`, `mean_sigma` και `h_v`$= \|v^\top Z_r - v^\top\|_1$ (ένα γινόμενο με τον $Z_r^\top$).
- Η `structural_features(ops)` επιστρέφει κάθε παρατηρήσιμο καθολικό στατιστικό της μελέτης: `pesc_M` ($\bar{P}$), `pesc_M_linked` (μέση τιμή στις μη κρεμάμενες σελίδες), `mean_k`, `pesc_H_block` (διαφυγή από το μπλοκ υπό τον H: μερίδιο των εξερχόμενων τόξων μιας σελίδας που εγκαταλείπουν το μπλοκ της· $1 - |\mathcal{A}_{(u)}|/n$ για κρεμάμενες σελίδες), `inter_arc_frac`, `mean_outdeg`, `log_mean_outdeg`, `dangling_frac`, `zero_in_frac` (σελίδες χωρίς εισερχόμενους συνδέσμους), `n`, `N`, `m`, `mean_block_size`, `log_n`.

5. Διαταραχές ([NG13, §4.2]). Τα A και B είναι μείγματα και όχι καθαροί μηχανισμοί: η `sparsify_arcs(g, keep_frac, rng)` μεταβάλλει τις κρεμάμενες σελίδες και τις σελίδες χωρίς εισερχόμενη σύνδεση, ενώ η `newly_added_pages(g, page_frac, rng, remove=0.9)` μπορεί επίσης να δημιουργήσει κρεμάμενες πηγές. Ο παραγόμενος πίνακας `V2_WP0_mixture_table.md` δίνει δ, ζ, h και h_{raw} από τον αδιατάρακτο γράφο έως την αυστηρότερη στάθμη· το `h_raw` μόνο του είναι σχεδόν τυφλό στο A.

6. Συνθετικές γεννήτριες.

- Η `sample_static_params(rng, n)` κληρώνει τις παραμέτρους της στατικής γεννήτριας: μέσο μέγεθος μπλοκ λογαριθμικά ομοιόμορφο στο $[4, 100]$, διασπορά μεγεθών μπλοκ, μέγεθος τομέα (3–30 μπλοκ), τοπικότητα τομέα $\lambda \in [0, 0.9]$, διασπορά λανθάνουσας ποιότητας $\sigma_q \in [0.8, 2]$, μερίδιο της ποιότητας σε επίπεδο μπλοκ (ICC) $\in [0, 0.8]$, εκθέτη ελκυστικότητας μπλοκ $\beta \in [0.5, 1.2]$ και θόρυβο, μέσο βαθμό εξόδου λογαριθμικά ομοιόμορφο στο $[2, 25]$, διασπορά βαθμών εξόδου, μερίδιο κρεμάμενων σελίδων $\in [0.02, 0.30]$ και πιθανότητα παραμονής στο μπλοκ $\varphi \in [0.30, 0.97]$.
- Η `generate_static_web(params, rng)` κατασκευάζει τον γράφο και τον επιστρέφει μαζί με ένα `PopulationModel`: τον *αναμενόμενο* περίπατο της γεννήτριας, διαθέσιμο σε κλειστή μορφή. Η μέθοδός του `pagerank(alpha, v)` υπολογίζει την πληθυσμιακή αλήθεια POP και το πεδίο του `q` τη λανθάνουσα ποιότητα Q.
- Οι `sample_growth_params` / `generate_growth_web` κατασκευάζουν το μοντέλο ανάπτυξης που χρησιμοποιείται για μεταφορά τοπολογίας: οι σελίδες φθάνουν μία προς μία, ιδρύουν νέο ιστότοπο (πιθανότητα 0.01–0.25) ή εντάσσονται σε υπάρχοντα αναλογικά προς το μέγεθός του, συνδέονται μέσω προνομιακής προσκόλλησης ως προς τον βαθμό εισόδου (μετατόπιση 0.2–5) εντός του ιστοτόπου τους με πιθανότητα φ, και μια φάση ενημέρωσης προσθέτει 10–50% επιπλέον τόξα.

7. Μετρικές κατάταξης. `kendall_tau_b(x, y)` (το τ-b της SciPy)· η `KendallRef(y)` υπολογίζει το τ-b έναντι σταθερής αναφοράς, ταξινομώντας την αναφορά μία φορά ($O(n \log n)$ ανά κλήση, ταυτόσημο με τη SciPy, επαληθευμένο με έλεγχο μονάδας)· οι `SpearmanRef`, `spearman_rho`, `centered_ranks` και `spearman_from_ranks` υπολογίζουν το ρ του Spearman με κοινόχρηστους υπολογισμούς τάξεων.

8. Βοηθητικά κανόνων. `clip_linear(x, c0, c1, lo, hi)`, `logistic(x, a, b, lo, hi)` και `interp_curve(curves, r_hat)` (γραμμική παρεμβολή των αποθηκευμένων καμπυλών $\tau(r)$ σε ένα προβλεπόμενο r).

9. Μηχανισμοί Σταδίου 2. Η `zt_multi(ops, X, r)` υπολογίζει το $Z_r^\top X$ για ένα σύνολο διανυσμάτων με διαφορετικό r ανά στήλη. Η `alpha_sweep(ops, r_values, alphas, tail=1e-13, block=32)` επιστρέφει το $\pi(\alpha; r)$ για όλες τις 67 τιμές του α και όλα τα ζητούμενα r από μία σειρά Neumann ανά r (Ενότητα 6.4). Η `rapr_reference(ops, r, a, b, K)` υπολογίζει το Random-α NCDawareRank $\mathbb{E}[\pi(A; r)]$, $A \sim \text{Beta}(a, b)$, με βάρη $w_k = B(a + k, b + 1)/B(a, b)$· για $a = b = 1$ προκύπτει το TotalRank, $w_k = 1/((k + 1)(k + 2))$.

Η πρόσθετη `mixed_damage(g, keep_frac, page_frac, rng, order)` συνθέτει τις υπάρχουσες διαταραχές B και A σε προκαθορισμένη σειρά για την ευαισθησία μειγμάτων· δεν αλλάζει τις πρωταρχικές συναρτήσεις.

5.2a `ncd_autotune.py` (πρακτικό εργαλείο ενός στιγμιότυπου)

Η `tune(src, dst, block, alpha_ref=0.85, baseline=None)` επιστρέφει το κλειδωμένο r του Σταδίου 1, την επικυρωμένη απόσβεση με αντιστοίχιση άγκυρας και διαγνωστικά κόστους $O(|E| + n)$. Υποστηρίζονται μόνο αναφορές στο 0.85 και στο 0.95· άλλες τιμές απορρίπτονται και το baseline αγνοείται με σαφή προειδοποίηση έως ότου επικυρωθεί κανόνας στα WP3/WP4.

Πρακτική συνταγή. Για αναφορά στο 0.85, καλέστε το εργαλείο με `alpha_ref=0.85`: επιστρέφει τον κανόνα r του Σταδίου 1 και $\alpha = 0.81$. Για αναφορά στο 0.95, χρησιμοποιήστε `alpha_ref=0.95`: επιστρέφει τον ίδιο κανόνα r του Σταδίου 1 και $\alpha = 0.93$. Η βέλτιστη σταθερά γι' αυτόν τον συνδυασμό είναι 0.920, μόνο 0.0002 τ πάνω από το

0.93. Το εργαλείο σκόπιμα δεν επιστρέφει το ίδιο r της αναφοράς $r = 0.10/\alpha_{\text{ref}}$· επιστρέφει το r του Σταδίου 1. Το `baseline` αγνοείται με προειδοποίηση, επειδή δεν έχει επικυρωθεί κανένας κανόνας baseline.

5.3 `decode_cnr2000.py` και `prepare_real_graphs.py`

Το `decode_cnr2000.py [raw_dir]` ανοίγει τα αρχεία BVGraph του cnr-2000 (Laboratory for Web Algorithmics) με το `webgraph.BvGraph`, διαβάζει κάθε λίστα διαδόχων και γράφει το `cnr2000_edges.npz` (`src`, `dst`, `n`· 325 557 σελίδες και 3 216 152 τόξα, ελεγμένα έναντι του αρχείου `.properties`). Αναπαράγει ακριβώς τη λίστα τόξων που χρησιμοποιήθηκε στα πειράματα.

Το `prepare_real_graphs.py [names…]` γράφει τα `data/real/<name>.npz` (`n`, `src`, `dst`, `block`) και το `data/real/summary.json` (μεγέθη, στατιστικά μπλοκ, μερίδιο τόξων εντός μπλοκ, μερίδιο κρεμάμενων σελίδων, μέσος βαθμός εξόδου) για πέντε γράφους:

Όνομα	Αρχείο πηγής	Μπλοκ
`cnr2000`	`../data/cnr2000/cnr2000_edges.npz`	προσέγγιση hosts: άπληστη μεγιστοποίηση της κατευθυνόμενης τμηματοποιότητας υπό περιορισμό συνέχειας στα αναγνωριστικά σελίδων σε σειρά URL (7 604 τμήματα)
`wikics`	`../data/other/wikics_data.json` (WikiCS, Mernyei & Cangea 2020)	10 θεματικές ετικέτες
`cora_full`	`../data/other/g2g_cora.npz` (CitationFull, Bojchevski & Günnemann 2018)	70 θεματικές ετικέτες
`cora_ml`	`../data/other/g2g_cora_ml.npz`	7 θεματικές ετικέτες
`citeseer`	`../data/other/g2g_citeseer.npz`	6 θεματικές ετικέτες

Οι βρόχοι και τα διπλά τόξα αφαιρούνται. Η προσέγγιση hosts είναι αναγκαία επειδή η λίστα URL του cnr-2000 δεν διανέμεται· η LAW αριθμεί τις σελίδες σε λεξικογραφική σειρά URL, οπότε κάθε host είναι ένα διάστημα αναγνωριστικών, και η `contiguous_modularity_segmentation` ξεκινά από μονοσύνολα και συγχωνεύει επαναληπτικά το γειτονικό ζεύγος τμημάτων με το μεγαλύτερο θετικό κέρδος κατευθυνόμενης τμηματοποιότητας

$$\Delta Q(a,b) = \frac{e_{ab} + e_{ba}}{m} - \frac{\text{out}_a\,\text{in}_b + \text{out}_b\,\text{in}_a}{m^2},$$

όπου $e_{ab} + e_{ba}$ είναι το πλήθος των τόξων μεταξύ των δύο τμημάτων (μια ουρά προτεραιότητας κρατά τις υποψήφιες συγχωνεύσεις, με οκνηρή ακύρωση των παρωχημένων εγγραφών)· οι σελίδες χωρίς τόξα εντάσσονται στο τμήμα στα αριστερά τους. Οι διαμερίσεις σε θεματικές ετικέτες ακολουθούν το κριτήριο της «κατηγορίας του περιεχομένου», το οποίο το [NG13, §5] αναφέρει ως αποδεκτή διάσπαση.

Ο Πίνακας 2 του [NG13] συγκρίνει $(\eta, \mu) = (0.75, 0.10)$ με PageRank στο 0.85 και $(0.85, 0.10)$ με PageRank στο 0.95. Τα πειράματα κατάταξης εκτελούν το NCDawareRank με συνολική απόσβεση 0.95 έναντι PageRank στο 0.85· δεν συγκρίνουν το 0.85 με το 0.95 ως προς την ποιότητα κατάταξης. Στο SELF η αναφορά μετακινείται μαζί με τον υποψήφιο. Το ακριβές αμφίπλευρο Wilcoxon έχει κατώφλι p 0.0625 για $n = 5$ και 0.0078 για $n = 8$.

5.4 `run_experiments.py` (οδηγός πειραμάτων)

```
python3 run_experiments.py stage1 --panel calib [--workers 2]
python3 run_experiments.py stage2 --panel test,topo --workers 2
python3 run_experiments.py stage1 --panel all
```

Η `panel_specs(panel)` απαριθμεί τους γράφους βάσης ενός συνόλου με τους σπόρους τους (Ενότητα 8)· η `make_base(spec)` παράγει ή φορτώνει τον γράφο βάσης. Οι εργασίες εκτελούνται σε δεξαμενή διεργασιών, με πρώτους τους μεγαλύτερους γράφους.

Στάδιο 1 (`run_base`). Για κάθε γράφο βάσης: κατασκευάζονται οι τελεστές· υπολογίζονται οι αναφορές NCD και PR (ανοχή 10^{-12}, 10^{-11} για γράφους άνω των 10^5 σελίδων), η POP για τους στατικούς γράφους και οι κατατάξεις του

πλήρους γράφου για κάθε r του R_GRID (απαιτούνται από την SELF). Στη συνέχεια, για κάθε επίπεδο διαταραχής και επανάληψη, ανακατασκευάζονται οι τελεστές στον παρατηρούμενο γράφο, υπολογίζονται τα structural_features, γίνεται κατάταξη με NCDawareRank$(\alpha_0 = 0.85, r)$ για όλες τις 100 τιμές του r (με εκκίνηση από την προηγούμενη λύση, ανοχή 10^{-10}) και αποθηκεύονται το τ-b του Kendall και το ρ του Spearman έναντι κάθε αλήθειας, καθώς και οι τιμές στο κανονικό r. Έξοδος: results/stage1/<panel>/<base>.npz με πίνακες tau, rho (στιγμιότυπα × αλήθειες × r), tau_can, rho_can, iters και ένα JSON meta (προδιαγραφή, παράμετροι γεννήτριας, γραμμές χαρακτηριστικών, πλέγματα, χρόνος εκτέλεσης).

Στάδιο 2 (run_base_stage2). Αναπαράγει τα ίδια στιγμιότυπα. Αναφορές: NCD, NCD95, TOT (rapr_reference με $K = 20\,000$ όρους, 10 000 για μεγάλους γράφους), και POP και Q για στατικούς γράφους. Για κάθε στιγμιότυπο αξιολογεί τις έξι ρυθμίσεις του r του R_NAMES (πίνακας κατωτέρω), υπολογίζει για καθεμία τα h, h_v και το μέσο άθροισμα εισερχόμενων μεταβάσεων, καθώς και τα h και h_v για $r = 0$ και $r = 1$, εκτελεί την alpha_sweep για όλα τα ενεργά r ταυτόχρονα, και αποθηκεύει τα τ και ρ έναντι των αληθειών που ορίζει το PAIRS. Έξοδος: results/stage2/<panel>/<base>.npz με tau, rho (στιγμιότυπα × ρυθμίσεις r × αλήθειες × 67 α), r, h, h_v, mean_sigma και meta.

Ρύθμιση r	Τιμή	Αξιολογείται έναντι
can	$0.10/0.85 = 0.118$	όλων των αληθειών
ng13	$0.10/0.95 = 0.105$	όλων των αληθειών
const	0.18 (καλύτερη σταθερά Σταδίου 1)	NCD, TOT, POP, Q
rule	clip$(0.242 - 0.143\bar{P}, 0.01, 0.99)$ (κλειδωμένος)	όλων των αληθειών
popLS	clip$(0.420 - 0.386\bar{P}, 0.01, 0.99)$	POP, Q (μόνο στατικοί)
popTAU	clip$(0.448 - 0.547\bar{P}, 0.01, 0.99)$	POP, Q (μόνο στατικοί)

Τα run_stage1_all.sh και run_stage2_all.sh εκτελούν διαδοχικά όλα τα σύνολα.

5.5 Σενάρια ανάλυσης του Σταδίου 1

- **stage1_analysis.py [--gt NCD|PR|POP|SELF|all].** Φορτώνει τα πρωτογενή αρχεία, κατασκευάζει το instances.csv (μία γραμμή ανά στιγμιότυπο: χαρακτηριστικά, παράμετροι γεννήτριας και, για κάθε αλήθεια, τα βέλτιστα κατά Kendall και κατά Spearman r^*, τ^*, το τ στο κανονικό r και στο $r = 0$, και την επιπεδότητα της καμπύλης). Προσαρμόζει τους υποψήφιους κανόνες στο calib (σταθερά· αποκομμένος γραμμικός (clipped-linear) με ελάχιστα τετράγωνα στο r^* και με μεγιστοποίηση του μέσου τ· παραλλαγές με ελεύθερα όρια· λογιστικός· εκθετικός· ισοτονικός· διαγνωστικοί κανόνες πολλών χαρακτηριστικών και ενισχυμένα δέντρα· ανταγωνιστικά χαρακτηριστικά όπως τα pesc_H_block, mean_k, inter_arc_frac, dangling_frac). Αξιολογεί κάθε κανόνα σε κάθε σύνολο (μέσα τ και ρ, μερίδιο του μαντείου, κάλυψη χάσματος σε σχέση με το κανονικό r, ζευγαρωτοί έλεγχοι έναντι του κανονικού r και έναντι της σταθεράς), εκτελεί ομαδοποιημένη 8-πλή διασταυρωμένη επικύρωση, και γράφει τα fits_<GT>.json, summary_<GT>.csv και diagnostics_<GT>.json (ανώτατο όριο θορύβου, αποσύνθεση εντός/μεταξύ, συμφωνία Kendall–Spearman, μερίδιο μαντείων στα όρια του πλέγματος).
- **stage1_decomposition.py.** Αποσύνθεση της διασποράς του r^* για κάθε αλήθεια (ταυτότητα γράφου, επίπεδο διαταραχής, και τα δύο· ενισχυμένα δέντρα στις κρυφές παραμέτρους της γεννήτριας· ridge στα παρατηρήσιμα· μόνο το $\bar{P}$) και συσχετίσεις του μέσου r^* ανά γράφο με κάθε κρυφή παράμετρο (decomposition.json).
- **stage1_feature_probe.py.** Ένα προκαθορισμένο διαγνωστικό τριών στατιστικών πληροφοριακότητας των μπλοκ (corr_HM_log, icc_indeg, disp_H) σε αναπαραγόμενα στιγμιότυπα (probe_features.csv).
- **stage1_crosstruth.py.** Αξιολογεί κανόνες προσαρμοσμένους υπό μία αλήθεια έναντι κάθε άλλης (crosstruth.csv) και αναλύει το σύνολο των πραγματικών δικτύων ανά γράφο (real_by_graph.csv).
- **stage1_tables.py.** Γράφει τους πίνακες του Σημείου Ελέγχου 1 (checkpoint1_tables.md).

5.6 Σενάρια ανάλυσης του Σταδίου 2

- **stage2_analysis.py [--pipelines-only].** Φορτώνει τα αρχεία του Σταδίου 2, υπολογίζει το μαντείο α^* (argmax του τ στο $\alpha \in [0.40, 0.99]$) και την εκδοχή του χωρίς περιορισμό, και για κάθε ζεύγος (ρύθμιση r, αλήθεια, χαρακτηριστικό $\in \{h, h_v\}$) προσαρμόζει τις υποψήφιες μορφές της g: σταθερά, αποκομμένος γραμμικός (ελάχιστα τετράγωνα και βέλτιστος ως προς τ), ελεύθερα όρια, λογιστικός, ισοτονικός, προϋπολογισμός

μετατόπισης $c/(c+x)$ και ενισχυμένα δέντρα σε όλα τα παρατηρήσιμα (διαγνωστικό ανώτατο όριο). Κάθε κανόνας αποκόπτεται στο $[0.40, 0.99]$ και αξιολογείται με γραμμική παρεμβολή των αποθηκευμένων καμπυλών $\tau(\alpha)$ στο μη ομοιόμορφο πλέγμα. Γράφει τα `instances.csv`, `fits.json`, `summary.csv` (κανόνας × σύνολο: μέσο τ, διαφορές έναντι του $\alpha = 0.85$ και έναντι της σταθεράς με p του Wilcoxon, κάλυψη χάσματος, CV τ), `diagnostics.json` (συσχετίσεις εντός/μεταξύ, κατανομή του α^*, έλεγχος $\max|\overline{\Sigma}_{\text{in}} - 1|$) και `pipelines.csv` (πλήρεις διαδικασίες (r, α) έναντι των δύο στατικών ρυθμίσεων για κάθε αλήθεια και σύνολο).

- **`stage2_decomposition.py`.** Αποσύνθεση της διασποράς του α^* (με το h ως χαρακτηριστικό ενδιαφέροντος) και οι άγκυρες α^* στον αδιατάρακτο γράφο (`decomposition.json`).
- **`stage2_rapr_anchor.py [n_graphs=16]`.** Έλεγχος δόσης–απόκρισης: αναφορές Random-α με εκ των προτέρων κατανομές Beta(3,7), Beta(5,5), Beta(1,1), Beta(7,3), Beta(8.5,1.5) (μέσες τιμές 0.30, 0.50, 0.50, 0.70, 0.85)· γράφει το `rapr_anchor.csv`.
- **`stage2_upper_check.py [n_graphs=8]`.** Αξιολογεί το τ έναντι της Q για $\alpha \in \{0.99, 0.995, 0.999\}$ (`upper_check.csv`).
- **`convergence_check.py [panels]`.** Επαναλήψεις της μεθόδου των δυνάμεων με ανοχή 10^{-6} για $\alpha = 0.85$ έναντι 0.81 (r του κανόνα) και 0.95 έναντι 0.93 ($r = 0.105$) (`convergence.csv`).
- **`bound_check.py [n_calib=4]`.** Λόγος των δύο μελών του φράγματος μετατόπισης στους γράφους των ελέγχων μονάδας και σε γράφους βαθμονόμησης (`bound_check.csv`)· επιβεβαιώνει ότι ο λόγος δεν υπερβαίνει ποτέ τη μονάδα.
- **`verify_stage2.py`.** Επαναϋπολογίζει τους αριθμούς των διαδικασιών ανά σύνολο απευθείας από τα πρωτογενή αρχεία (χωρίς εισαγωγή κώδικα ανάλυσης) και τους τυπώνει μαζί με τον έλεγχο Wilcoxon της διαδικασίας δύο σταδίων.
- **`stage2_tables.py`.** Γράφει τους πίνακες του Σημείου Ελέγχου 2 (`checkpoint2_tables.md`).
- **`stage2_nonmonotone_search.py [--replay] [--workers 2]`.** Ελέγχει αν μπορεί να αξιοποιηθεί το σχήμα ανεστραμμένου V του α^* ως προς το h (το h μειώνεται υπό την αφαίρεση συνδέσμων και αυξάνεται υπό τις νεοεισαχθείσες σελίδες, ενώ το α^* μειώνεται και στις δύο). Επαναχρησιμοποιεί τις αποθηκευμένες επιφάνειες $\tau(\alpha)$ κάθε στιγμιοτύπου (καμία σάρωση δεν επαναλαμβάνεται· το τ σε ένα προβλεπόμενο α προκύπτει με παρεμβολή) και αναπαράγει τους διαταραγμένους γράφους με τους σπόρους και τη ροή τυχαίων αριθμών του `run_experiments.py stage2` μόνο για να υπολογίσει τα αθροίσματα στηλών ανά σελίδα (περίπου 15 δευτερόλεπτα), επιβεβαιώνοντας ότι τα h, r και το ποσοστό κρεμάμενων σελίδων της αναπαραγωγής ταυτίζονται με τα αποθηκευμένα (μέγιστη απόκλιση 2.2×10^{-16}). Στατιστικά: h, h_v· η απόκλιση χωρίς την επίδραση των κρεμάμενων σελίδων $h_{\text{raw}} = \text{mean}_v|1 - \Sigma_{\text{in}}(v) + (1-r)\delta|$, η σχετική εκδοχή της $h^{\text{rel}}_{\text{raw}}$ και η απόκλιση h^{H}_{raw} του πρωτογενούς πίνακα υπερσυνδέσμων· το ποσοστό κρεμάμενων σελίδων δ και το μερίδιο ζ των σελίδων χωρίς εισερχόμενο σύνδεσμο. Οικογένειες: αποκομμένος γραμμικός, ασύμμετρη και συμμετρική τέντα, κοίλη τετραγωνική, γκαουσιανό εξόγκωμα, ακριβείς κλιμακωτές συναρτήσεις δύο και τριών περιοχών, γραμμική spline δύο κόμβων (καθεμία με ελάχιστα τετράγωνα και με απευθείας μεγιστοποίηση του τ: πλέγμα, έπειτα Nelder–Mead και Powell· κορυφή των κανόνων στο h στο $[0.50, 0.70]$), αποκομμένοι γραμμικοί κανόνες δύο μεταβλητών, τέντα+$c\,s$, κελιά 3×3 και ενισχυμένα δέντρα στα (h, δ) και (h, ζ), καθώς και τα μη εφαρμόσιμα διαγνωστικά $h - h_0$ (τιμή του ίδιου του αδιατάρακτου γράφου) και η καλύτερη σταθερά ανά γράφο. Ακριβής 8-πλή CV ανά γράφο με επαναπροσαρμογή της σταθεράς σε κάθε τμήμα· ζευγαρωτός έλεγχος Wilcoxon και bootstrap στις μέσες τιμές ανά γράφο· διόρθωση Holm στα τέσσερα σύνολα εκτός δείγματος· συνολικός έλεγχος εκτός δείγματος σε 73 γράφους. Ο κανόνας απόφασης (κέρδος ≥ 0.0005 με $p < 0.05$ στη CV και στα σύνολα εκτός δείγματος μαζί, χωρίς σημαντική κατά Holm απώλεια) ορίζεται στην τεκμηρίωση του σεναρίου. Ρυθμίσεις: NCD με το r του κανόνα του Σταδίου 1 (κύρια), NCD95 με $r = 0.105$ και TOT (ευαισθησία). Γράφει τα `nonmono_features.csv`, `nonmono_rules.csv` και `nonmono_summary.json`· περίπου 8 λεπτά με δύο διεργασίες.

5.7 `generate_figures.py` και `fig_lang.py`

```
python3 generate_figures.py stage1 [--only NAME] [--lang en|gr]
python3 generate_figures.py stage2 [--only NAME] [--lang en|gr]
```

Το σενάριο γράφει PDF (για το LaTeX) και PNG (για προεπισκόπηση) στο `figures/` ή, με `--lang gr`, στο `figures_gr/`. Η `fig_lang.patch()` περιβάλλει τα σημεία εισόδου κειμένου της matplotlib (τίτλοι, ετικέτες αξόνων, ετικέτες υποδιαιρέσεων, ελεύθερο κείμενο, ετικέτες υπομνημάτων, ετικέτες χρωματικής κλίμακας), ώστε κάθε συμβολοσειρά να περνά από μια διατεταγμένη λίστα κυριολεκτικών αντικαταστάσεων και κανονικών εκφράσεων, με πρώτες τις μακρύτερες· τα μαθηματικά σε `$…$` μένουν ανέγγιχτα και τα γράμματα υποσχημάτων (a)–(d) γίνονται (α)–(δ). Τα σχήματα χρησιμοποιούν επικυρωμένη τρίχρωμη κατηγορική παλέτα (μπλε, πορτοκαλί, γαλαζοπράσινο), λεπτά πλέγματα και

υπομνήματα έξω από τα δεδομένα.

5.8 `make_paper_assets.py`

Διαβάζει κάθε αρχείο αποτελεσμάτων και γράφει το `paper/generated/macros.tex` (περίπου 300 μακροεντολές `\newcommand`, καθεμία ανεξάρτητη από τον τρόπο στοιχειοθεσίας: οι προσημασμένοι αριθμοί και οι δυνάμεις του δέκα περικλείονται σε `\ensuremath`), τα `paper/generated/en/tab_*.tex` και `paper/generated/gr/tab_*.tex` (οι ίδιοι πίνακες με αγγλικές ή ελληνικές λεξάντες και ετικέτες) και το `results/paper_numbers.json`. Και τα δύο κείμενα κάνουν `\input` αυτά τα αρχεία, οπότε μια επανάληψη της ανάλυσης ενημερώνει με συνέπεια κάθε αριθμό και πίνακα και των δύο εργασιών.

5.9 Έλεγχοι μονάδας

Το `python3 tests/test_lib.py` ελέγχει: τους πίνακες M, R, A του μικρού γράφου του [NG13, Σχ. 1] στοιχείο προς στοιχείο· τη στοχαστικότητα κατά γραμμές των H, M και P· την παραγοντοποιημένη μέθοδο των δυνάμεων έναντι πυκνής επίλυσης· το Θεώρημα 1 του [NG13] ($|\lambda_2(P)| \le \eta + \mu$) και το Θεώρημα 2 (στάσιμο διάνυσμα σε επίπεδο μπλοκ)· την πιθανότητα διαφυγής από το μπλοκ· τα αθροίσματα εισερχόμενων μεταβάσεων και τη μοναδιαία μέση τιμή τους· την ακριβή μορφή της [NG13, Παρατήρηση 1] (ένα μπλοκ δίνει $M = ee^{\top}/n$· μονοσύνολα μπλοκ δίνουν τον νωθρό περίπατο $(D + I)^{-1}(\mathrm{Adj} + I)$ και όχι τον H)· το πληθυσμιακό μοντέλο· και τις διαταραχές.

Το `python3 tests/test_stage2.py` ελέγχει: την `KendallRef` έναντι της SciPy με ισοβαθμίες· την `alpha_sweep` έναντι της μεθόδου των δυνάμεων για κάθε α (έως 10^{-11} σε L_1)· τη διατήρηση των ακριβών ισοβαθμιών· το TotalRank έναντι αριθμητικής ολοκλήρωσης Gauss–Legendre πυκνών επιλύσεων· τις ταυτότητες για το h και το $\overline{\Sigma}_{\text{in}} = 1$ και το h_v έναντι παραγώγου πεπερασμένων διαφορών· και το φράγμα μετατόπισης για κάθε α του πλέγματος.

Το `python3 tests/test_nonmono.py` ελέγχει: τον διανυσματικό υπολογισμό του μέσου τ για πολλά διανύσματα παραμέτρων έναντι παρεμβολής γραμμή προς γραμμή· ότι οι ακριβείς προσαρμογές κλιμακωτών συναρτήσεων πετυχαίνουν το βέλτιστο της εξαντλητικής αναζήτησης (μέσο τ και ελάχιστα τετράγωνα)· ότι κάθε μη μονότονη οικογένεια εκφυλίζεται στη σταθερά όταν μηδενίζονται οι κλίσεις της και ότι η τέντα είναι μονοκόρυφη με αποκομμένη κορυφή· την ταυτότητα μεταξύ των διορθωμένων αθροισμάτων στηλών και των αθροισμάτων στηλών του $(1 - r)H_{\text{raw}} + rM$ (μέση τιμή $1 - (1 - r)n_{\text{d}}/n$)· και ότι η αναπαραγωγή ενός γράφου βαθμονόμησης δίνει τα αποθηκευμένα h, r και ποσοστό κρεμάμενων σελίδων.

Η `python3 tests/test_autotune.py` ελέγχει την ισότητα των τύπων, τη συνέπεια με την κεντρική βιβλιοθήκη και τις διαδρομές μη υποστηριζόμενης άγκυρας και προειδοποίησης baseline. Η `python3 verify_v2.py` ελέγχει ανεξάρτητα τα νέα αρχεία μειγμάτων και διαδικασιών χωρίς εισαγωγή των scripts ανάλυσης.

6. Πολυπλοκότητα και μηχανισμοί των επιλυτών

Σε όλη την ενότητα, $m = |\mathcal{E}|$ είναι το πλήθος των τόξων, n το πλήθος των σελίδων και N το πλήθος των μπλοκ· $\mathrm{nnz}(H) = m$ και $\mathrm{nnz}(R) \le n + m$.

6.1 Κατασκευή των τελεστών σε χρόνο και χώρο $O(m + n)$

Ισχυρισμός. Οι $H^{\top}$, τα μη μηδενικά στοιχεία του R, η απεικόνιση μπλοκ A και το v κατασκευάζονται σε χρόνο $O(m + n)$ με μνήμη $O(m + n)$.

Απόδειξη. Οι βαθμοί εξόδου απαιτούν ένα πέρασμα καταμέτρησης στα τόξα, $O(m + n)$. Ο $H^{\top}$ σε μορφή CSR είναι ταξινόμηση καταμέτρησης των τόξων κατά προορισμό, $O(m + n)$, με τιμή $1/d_u$ ανά τόξο. Για τον R, διατηρούμε έναν πίνακα $\mathrm{last}[1..N]$ με αρχική τιμή μηδέν· για κάθε σελίδα u επισκεπτόμαστε το δικό της μπλοκ και το μπλοκ κάθε εξερχόμενου γείτονα, και καταγράφουμε το ζεύγος (u, I) μόνο όταν $\mathrm{last}[I] \neq u$, θέτοντας έπειτα $\mathrm{last}[I] \leftarrow u$. Κάθε σελίδα κοστίζει $O(1 + d_u)$, οπότε όλα τα ζεύγη βρίσκονται σε χρόνο $O(\sum_u (1 + d_u)) = O(n + m)$· το πλήθος τους ανά σελίδα είναι το N_u, και οι τιμές $1/(N_u|\mathcal{A}_I|)$ απαιτούν τα μεγέθη των μπλοκ, ένα πέρασμα $O(n)$. Το v κοστίζει $O(n)$. Μνήμη: m στοιχεία για τον $H^{\top}$, το πολύ $n + m$ για τον $R^{\top}$, $n + N$ για την απεικόνιση και τα μεγέθη των μπλοκ, n για το v. □

Σημείωση υλοποίησης. Η βιβλιοθήκη βρίσκει τα ίδια ζεύγη με μία διανυσματοποιημένη κλήση `np.unique`, η οποία ταξινομεί $m' = n + (\text{τόξα μεταξύ μπλοκ})$ ακέραια κλειδιά, δηλαδή σε χρόνο $O(m' \log m')$. Για τα μεγέθη γράφων αυτής της μελέτης η ταξινόμηση είναι αμελητέο μέρος του χρόνου εκτέλεσης· η εκδοχή με πίνακα σημαδιών παραπάνω είναι αυτή που επιτυγχάνει το φράγμα.

6.2 Τα στατιστικά βαθμονόμησης σε $O(m+n)$ (Πρόταση 5 της εργασίας)

Ισχυρισμός. Τα $\{k_u\}$, $\bar{P}^{(M)}_{\text{esc}}$, $\Sigma^{(H)}_{\text{in}}$, $\Sigma^{(M)}_{\text{in}}$, $h(r)$ και $h_v(r)$ κοστίζουν χρόνο $O(m+n)$ και μνήμη $O(n+N)$ πέραν του γράφου.

Απόδειξη. Το $k_u = N_u - 1$ προκύπτει από την κατασκευή του R· το $\bar{P}$ απαιτεί ένα πέρασμα $O(n)$. Το $\Sigma^{(H)}_{\text{in}}(v) = \sum_{u \to v} 1/d_u + n_{\text{d}}/n$ απαιτεί ένα πέρασμα στα τόξα και μια πρόσθεση $O(n)$. Το $\Sigma^{(M)}_{\text{in}}$ συσσωρεύει το $1/N_u$ σε κάθε μπλοκ εγγύτητας κάθε σελίδας, $O(\text{nnz}(R))$, διαιρεί με τα μεγέθη των μπλοκ και αντιγράφει στις σελίδες, $O(n)$. Το $h(r)$ απαιτεί ένα πέρασμα $O(n)$. Το $h_v(r) = \|v^\top Z_r - v^\top\|_1$ απαιτεί το $v^\top Z_r = (1-r)v^\top H + r(v^\top R)A$, δηλαδή ένα αραιό γινόμενο με τον $H^\top$ ($O(m+n)$ μαζί με τον όρο των κρεμάμενων σελίδων), ένα με τον $R^\top$ ($O(\text{nnz}(R))$) και μία συλλογή τιμών ($O(n)$). Η επιπλέον μνήμη είναι ο πίνακας σημαδιών και τα αθροίσματα ανά μπλοκ ($O(N)$) και ένας σταθερός αριθμός διανυσμάτων σελίδων ($O(n)$). □

Επειδή και τα δύο στατιστικά είναι παραπροϊόντα της κατασκευής του R, η διαδικασία δύο σταδίων δεν προσθέτει ασυμπτωτικό κόστος στο NCDawareRank.

6.3 Η μέθοδος των δυνάμεων

Μία επανάληψη κοστίζει $O(\text{nnz}(H) + \text{nnz}(R) + n)$: ένα αραιό γινόμενο με τον $H^\top$, τη διόρθωση των κρεμάμενων σελίδων, ένα γινόμενο με τον $R^\top$ που παράγει N μάζες μπλοκ, μία συλλογή τιμών προς τις σελίδες και τον όρο τηλεμεταφοράς.

Σύγκλιση. Με $x_k = \pi^{(k)\top}$, ο όρος τηλεμεταφοράς απαλείφεται στις διαδοχικές διαφορές: $x_{k+1} - x_k = \alpha(x_k - x_{k-1})Z_r$. Ένας στοχαστικός κατά γραμμές πίνακας δεν αυξάνει τη νόρμα L_1 ενός διανύσματος γραμμής, οπότε $\|x_{k+1} - x_k\|_1 \le \alpha^k \|x_1 - x_0\|_1 \le 2\alpha^k$. Ο κανόνας τερματισμού $\|x_{k+1} - x_k\|_1 < \varepsilon$ ικανοποιείται επομένως μετά από το πολύ $\lceil \ln(\varepsilon/2) / \ln \alpha \rceil + 1$ επαναλήψεις, και το συνολικό κόστος είναι $O((m+n)\log(1/\varepsilon)/\log(1/\alpha))$. Στην πράξη η συστολή είναι ταχύτερη (η υποκυρίαρχη ιδιοτιμή είναι $\alpha\lambda_2(Z_r)$ με $|\lambda_2(Z_r)| \le 1$, [NG13, Θεώρημα 1]), γι' αυτό οι μετρημένοι αριθμοί επαναλήψεων στο `convergence.csv` είναι αρκετά κάτω από αυτή την εκτίμηση. Μνήμη: τρία διανύσματα σελίδων πέραν των τελεστών.

6.4 Η σάρωση του α με σειρά Neumann

Για σταθερό r η κατάταξη έχει τη μορφή σειράς

$$\pi(\alpha)^\top = (1-\alpha)\sum_{k \ge 0} \alpha^k u_k, \qquad u_k = v^\top Z_r^k,$$

στην οποία μόνο τα βαθμωτά βάρη εξαρτώνται από το α. Η `alpha_sweep` υπολογίζει επομένως τα διαδοχικά διανύσματα $u_0 = v^\top$, $u_{k+1} = u_k Z_r$ μία φορά και συσσωρεύει από αυτά κάθε α_j του πλέγματος:

$$\hat{\pi}(\alpha_j)^\top = (1-\alpha_j)\sum_{k=0}^{K_j} \alpha_j^k u_k + \alpha_j^{K_j+1} u_{K_j+1}, \qquad K_j = \lceil \ln(\text{tail})/\ln \alpha_j \rceil,\ \text{tail} = 10^{-13}.$$

Ακρίβεια. Τα βάρη αθροίζουν στη μονάδα, $\sum_{k \le K}(1-\alpha)\alpha^k + \alpha^{K+1} = 1$, οπότε το $\hat{\pi}$ είναι διάνυσμα πιθανότητας. Το σφάλμα είναι $\pi - \hat{\pi} = \sum_{k>K}(1-\alpha)\alpha^k u_k - \alpha^{K+1}u_{K+1}$· και οι δύο όροι είναι διανύσματα πιθανότητας κλιμακωμένα κατά $\sum_{k>K}(1-\alpha)\alpha^k = \alpha^{K+1} \le \text{tail}$, επομένως $\|\pi - \hat{\pi}\|_1 \le 2\,\text{tail} = 2 \times 10^{-13}$.

Κόστος. Ο μεγαλύτερος δείκτης αποκοπής αντιστοιχεί στο $\alpha = 0.99$: $K_{\max} = \lceil \ln 10^{-13} / \ln 0.99 \rceil = 2\,979$ (για $\alpha = 0.40$ είναι μόλις 33). Η σάρωση εκτελεί $K_{\max} + 1$ γινόμενα με τον $Z_r^\top$, ομαδοποιημένα για όλες τις ζητούμενες τιμές του r (μία στήλη ανά r), δηλαδή $O(K_{\max}\,|r|\,(m+n))$, συν τη συσσώρευση. Τα διαδοχικά διανύσματα αποθηκεύονται προσωρινά σε ομάδες των $B = 32$ (16 για μεγάλους γράφους) και ενσωματώνονται στις 67 εξόδους με

ένα πυκνό γινόμενο πινάκων (GEMM) ανά ομάδα και ανά r, χρησιμοποιώντας έναν πίνακα βαρών που περιέχει ήδη τους παράγοντες $(1-\alpha_j)\alpha_j^k$ και τη διόρθωση της ουράς· οι έξοδοι των οποίων η σειρά έχει τελειώσει παραλείπονται. Η συσσώρευση κοστίζει $O(K_{\max} \cdot n_\alpha \cdot n)$ πράξεις κινητής υποδιαστολής ανά r, αλλά εκτελείται με ταχύτητα BLAS. Μνήμη: $O(|r|\, n_\alpha\, n)$ για τις εξόδους και $O(|r|\, B\, n)$ για τον ενδιάμεσο χώρο. Σε σύγκριση με 67 χωριστές εκτελέσεις της μεθόδου των δυνάμεων, η σάρωση μοιράζεται κάθε αραιό γινόμενο μεταξύ όλων των τιμών του α.

Συμφωνία. Οι έλεγχοι μονάδας επιβεβαιώνουν συμφωνία με τη μέθοδο των δυνάμεων έως 10^{-11} σε L_1 για κάθε α του πλέγματος, και η αναπαραγωγή του Σταδίου 2 αναπαράγει τις τιμές τ του Σταδίου 1 στο $\alpha = 0.85$ έως 10^{-6}.

6.5 Γιατί έχουν σημασία οι ακριβείς ισοβαθμίες

Σελίδες με ταυτόσημες εισερχόμενες γειτονιές στο ίδιο μπλοκ λαμβάνουν ταυτόσημες βαθμολογίες σε ακριβή αριθμητική. Η μέθοδος των δυνάμεων και η σάρωση Neumann εφαρμόζουν την ίδια ακολουθία πράξεων κινητής υποδιαστολής σε τέτοιες σελίδες (τις ίδιες γραμμές CSR, την ίδια μάζα μπλοκ, το ίδιο βάρος τηλεμεταφοράς), οπότε οι βαθμολογίες τους παραμένουν πανομοιότυπες bit προς bit, όπως επαληθεύει ο έλεγχος μονάδας `test_alpha_sweep_ties`. Ένας άμεσος επιλυτής με οδήγηση αναμειγνύει γραμμές και σπάει αυτές τις ισοβαθμίες με θόρυβο στρογγύλευσης. Το τ-b του Kendall μετρά τότε ψευδή σύμφωνα ή ασύμφωνα ζεύγη· στους γράφους των 2 000 σελίδων αυτό μείωσε το τ κατά 0.002–0.004, σημαντικό κλάσμα των φαινομένων που μελετώνται. Όλοι οι επιλυτές του πακέτου χρησιμοποιούν επομένως μόνο γινόμενα και κλιμακώσεις ανεξάρτητες από τα στοιχεία.

6.6 Λοιπά κόστη

- `rapr_reference`: $K+1$ γινόμενα με τον $Z_r^\top$, $O(K(m+n))$· η μάζα πιθανότητας πέραν των K όρων ($1/(K+2)$ για το TotalRank) αποδίδεται στο τελευταίο διάνυσμα.
- `KendallRef`: $O(n \log n)$ ανά αξιολόγηση (μία ευσταθής ταξινόμηση και μια καταμέτρηση ασυμφωνιών με συγχωνευτική ταξινόμηση).
- Ανά στιγμιότυπο του Σταδίου 2: μία σάρωση ανά ενεργή ρύθμιση του r (ομαδοποιημένα) και $n_\alpha \times$ (αλήθειες) συσχετίσεις κατατάξεων.

7. Αλήθειες αναφοράς

Όλες οι αναφορές υπολογίζονται στον **πλήρη** γράφο βάσης (εκτός από την Q, που είναι λανθάνουσα) με ισοκατανεμημένη ανά μπλοκ τηλεμεταφορά και ομοιόμορφες κρεμάμενες γραμμές. Μια μέθοδος βαθμολογείται με το τ-b του Kendall μεταξύ της κατάταξής της στον **παρατηρούμενο** (διαταραγμένο) γράφο και της αναφοράς.

Αλήθεια	Ορισμός	Σύνολα	Ρόλος
NCD	NCDawareRank, $(\alpha, r) = (0.85, 0.118)$, δηλαδή $(\eta, \mu) = (0.75, 0.10)$	όλα	κύρια αλήθεια και των δύο σταδίων
NCD95	NCDawareRank, $(\alpha, r) = (0.95, 0.105)$, δηλαδή $(\eta, \mu) = (0.85, 0.10)$, η ρύθμιση των πειραμάτων κατάταξης του [NG13]	όλα (Στάδιο 2)	ευαισθησία: άγκυρα στο 0.95
PR	PageRank ($r = 0$), $\alpha = 0.85$	όλα (Στάδιο 1)	μεθοδολογική αντιπαραβολή: ευνοεί $r \to 0$
SELF	η κατάταξη του ίδιου του υποψηφίου στον πλήρη γράφο με τα ίδια (α, r), το πρωτόκολλο σταθερότητας του [NG13]	όλα (Στάδιο 1)	αποδεικνύεται εκφυλισμένη: επιβραβεύει $r \to 1$ και $\alpha \to 0$
POP	PageRank με 0.85 του αναμενόμενου περιπάτου της στατικής γεννήτριας	στατικά σύνολα	πληθυσμιακή σημαντικότητα που δεν ορίζεται από καμία μέθοδο
Q	λανθάνουσα ποιότητα q της στατικής γεννήτριας	στατικά σύνολα (Στάδιο 2)	αναφορά ανεξάρτητη από περιπάτους

Αλήθεια	Ορισμός	Σύνολα	Ρόλος
TOT	$\int_0^1 \pi(\alpha)\,\mathrm{d}\alpha = \sum_k v^\top Z_r^k/((k+1)(k+2))$ με $r = 0.118$: TotalRank, δηλαδή Random-α NCDawareRank με εκ των προτέρων Beta(1,1) (μέση τιμή 0.5)	όλα (Στάδιο 2)	αναφορά ολοκληρωμένη ως προς α
Οικογένεια RAPr	$\mathbb{E}[\pi(A)]$, $A \sim \mathrm{Beta}(a, b)$, μέσες τιμές 0.30–0.85	16 γράφοι βαθμονόμησης	έλεγχος δόσης–απόκρισης της αγκύρωσης

Γιατί πολλές αλήθειες; Η μελέτη διαπίστωσε ότι η βέλτιστη απόσβεση καθορίζεται από την ίδια την αναφορά: στον αδιατάρακτο γράφο, το α^* είναι 0.852 (NCD), 0.950 (NCD95), 0.547 (TOT), 0.767 (POP) και 0.971 (Q). Η αναφορά μίας μόνο αλήθειας θα μετέτρεπε μια ιδιότητα της αναφοράς σε φαινομενική ιδιότητα της μεθόδου.

8. Σύνολα, σπόροι και διαταραχές

Σύνολο	Γεννήτρια	Γράφοι βάσης	Σπόροι	n	Επαναλ.	Στιγμιότυπα (Στάδιο 2)	Ρόλος
`calib`	στατικός ιστός με μπλοκ	64	1000–1063	2 000	2	1 856	προσαρμογή
`test`	στατικός, ανεξάρτητοι σπόροι	32	5000–5031	2 000	1	480	εκτός δείγματος
`scale`	στατικός, 8× μεγαλύτερος	12	9000–9011	16 000	1	180	μεταφορά κλίμακας
`topo`	ανάπτυξη / προνομιακή προσκόλληση	24	13000–13023	3 000	1	360	μεταφορά τοπολογίας
`real`	Πίνακας 1 της εργασίας	5	17000–17004	2 995–325 557	2 (1 για το cnr-2000)	131	πραγματικά δίκτυα

Κάθε γράφος βάσης δίνει το αδιατάρακτο στιγμιότυπο A1.0, το Πείραμα A (διατήρηση του 90%, 80%, …, 20% των τόξων) και το Πείραμα B (το 10%, …, 60% των σελίδων χάνει κάθε εισερχόμενο τόξο με πιθανότητα 0.9), κάθε επίπεδο με τον αναφερόμενο αριθμό επαναλήψεων: $1 + 14 \times$ επαναλήψεις στιγμιότυπα ανά γράφο βάσης, 3 007 στιγμιότυπα συνολικά. Το A1.0 εξαιρείται από τις αξιολογήσεις υπό τις NCD, NCD95 και TOT, όπου αποτελεί τετριμμένο πρόβλημα ανάκτησης.

9. Στατιστική μεθοδολογία

- **Μαντεία.** $r^* = \arg\max_{r\in[0.01,0.99]} \tau$ για $\alpha_0 = 0.85$· $\alpha^* = \arg\max_{\alpha\in[0.40,0.99]} \tau$ με το r κλειδωμένο.
- **Οι κανόνες** προσαρμόζονται μόνο στο `calib`· οι προσαρμογές βέλτιστες ως προς τ μεγιστοποιούν το μέσο τ βαθμονόμησης στις αποθηκευμένες καμπύλες (προσαρμογή με γνώμονα την απόφαση), ενώ οι προσαρμογές ελαχίστων τετραγώνων παλινδρομούν τις βέλτιστες τιμές.
- **Η επιλογή μοντέλου** χρησιμοποιεί 8-πλή διασταυρωμένη επικύρωση ομαδοποιημένη ανά γράφο βάσης.
- **Οι ζευγαρωτές συγκρίσεις** χρησιμοποιούν μέσες διαφορές ανά γράφο με τον έλεγχο προσημασμένων τάξεων του Wilcoxon και εκατοστημοριακά διαστήματα bootstrap 20 000 επαναδειγματοληψιών ανά γράφο· αναφέρεται και το πλήθος των γράφων στους οποίους υπερέχει μια πολιτική. Οι μέσες τιμές συνόλων στους πίνακες σταθμίζουν τα στιγμιότυπα, ενώ οι ζευγαρωτοί έλεγχοι σταθμίζουν τους γράφους, κάτι που έχει σημασία μόνο στο σύνολο των πραγματικών δικτύων (ανά γράφο $+0.0017$ έναντι ανά στιγμιότυπο $+0.0000$ για τη διαδικασία δύο σταδίων).

- **Η κάλυψη του χάσματος** είναι $(\tau_{\text{rule}} - \tau_{\text{static}})/(\tau_{\text{oracle}} - \tau_{\text{static}})$.
- **Αποσύνθεση εντός/μεταξύ**: συσχετίσεις των αποκεντρωμένων τιμών εντός γράφων και των μέσων τιμών των γράφων μεταξύ γράφων (δομή Simpson).
- **Αποσύνθεση διασποράς**: μερίδια ANOVA εντός δείγματος της ταυτότητας του γράφου και του επιπέδου διαταραχής· R^2 εκτός δείγματος (ομαδοποιημένη CV) ενισχυμένων δέντρων στις κρυφές παραμέτρους της γεννήτριας, παλινδρόμησης ridge σε όλα τα παρατηρήσιμα στατιστικά, και του αποκομμένου γραμμικού κανόνα στο στατιστικό μόνο του.

10. Έξοδοι: αρχεία, σχήματα και πίνακες

10.1 Αρχεία αποτελεσμάτων

Αρχείο	Περιεχόμενο
`results/stage1/<panel>/<base>.npz`	πρωτογενείς καμπύλες $\tau(r)$, $\rho(r)$ του Σταδίου 1 ανά στιγμιότυπο και αλήθεια· επαναλήψεις· μεταδεδομένα
`results/stage1/instances.csv`	μία γραμμή ανά στιγμιότυπο: χαρακτηριστικά, παράμετροι γεννήτριας, r^*, τ^*, κανονικές τιμές ανά αλήθεια
`results/stage1/fits_<GT>.json`	κάθε προσαρμοσμένος κανόνας του Σταδίου 1 (μορφή, παράμετροι, τύπος)
`results/stage1/summary_<GT>.csv`	κανόνας × σύνολο: τ, ρ, μερίδιο του μαντείου, κάλυψη χάσματος, έλεγχοι έναντι κανονικού και σταθεράς, CV τ
`results/stage1/diagnostics_<GT>.json`	ανώτατο όριο θορύβου, εντός/μεταξύ, όρια, συμφωνία Kendall–Spearman, CV
`results/stage1/decomposition.json`	αποσύνθεση διασποράς του r^* ανά αλήθεια
`results/stage1/crosstruth.csv`, `real_by_graph.csv`	αξιολόγηση μεταξύ αληθειών, αποτελέσματα πραγματικών δικτύων ανά γράφο
`results/stage2/<panel>/<base>.npz`	πρωτογενείς καμπύλες $\tau(\alpha)$, $\rho(\alpha)$ του Σταδίου 2 ανά στιγμιότυπο, ρύθμιση r και αλήθεια· r, h, h_v
`results/stage2/instances.csv`	ανά στιγμιότυπο: χαρακτηριστικά, r, h, h_v ανά ρύθμιση r, α^*, τ^*, τ στο 0.85/0.95 ανά ζεύγος
`results/stage2/fits.json`	προσαρμοσμένοι κανόνες του Σταδίου 2 ανά (ρύθμιση r, αλήθεια, χαρακτηριστικό)
`results/stage2/summary.csv`	αποτελέσματα κανόνα × σύνολο του Σταδίου 2
`results/stage2/pipelines.csv`	πλήρεις διαδικασίες έναντι των δύο στατικών ρυθμίσεων, κάθε αλήθεια και σύνολο
`results/stage2/diagnostics.json`	συσχετίσεις, στατιστικά του α^*, CV, αριθμητικοί έλεγχοι
`results/stage2/decomposition.json`	αποσύνθεση διασποράς και άγκυρες του α^*
`results/stage2/rapr_anchor.csv`	δόση–απόκριση: α^* ανά στιγμιότυπο και εκ των προτέρων κατανομή
`results/stage2/upper_check.csv`	τ έναντι της Q στα 0.99, 0.995, 0.999
`results/stage2/convergence.csv`	πλήθος επαναλήψεων ανά στιγμιότυπο
`results/stage2/bound_check.csv`	τα δύο μέλη του φράγματος μετατόπισης ανά (γράφο, r, α)
`results/stage2/nonmono_features.csv`	στατιστικά ανά στιγμιότυπο από την αναπαραγωγή: επανυπολογισμένο h, h_{raw}, $h^{\text{rel}}_{\text{raw}}$, h^{H}_{raw}, δ
`results/stage2/nonmono_rules.csv`	μία γραμμή ανά (ρύθμιση, κανόνα): παράμετροι, σύγκριση με τη σταθερά εντός δείγματος, στη CV και εκτός δείγματος, σημαίες απόφασης
`results/stage2/nonmono_summary.json`	τροχιές στα δύο πειράματα, κατευθύνσεις μεταβολής, διασπορά του h_0, απόφαση
`results/paper_numbers.json`	κάθε αριθμός που αναφέρεται στα κείμενα

10.2 Σχήματα

1. **`stage1_calibration_scatter.`** Βέλτιστο r^* έναντι του $\bar{P}$ στο `calib`. Υπόσχημα (α): αλήθεια NCD με τους προσαρμοσμένους κανόνες και το κανονικό $r^{\cdot}$ υπόσχημα (γ): αλήθεια POP· υποσχήματα (β) και (δ): τα ίδια σημεία με ενωμένη τη σειρά διαταραχών κάθε γράφου και σημειωμένες τις μέσες τιμές των γράφων, όπου φαίνονται η απότομη κλίση εντός γράφων και η επίπεδη κλίση μεταξύ γράφων (δομή Simpson).

2. **`stage1_gt_sensitivity`.** r^* έναντι του $\bar{P}$ υπό τις NCD, PR, SELF και POP: η PR ωθεί το r^* στο κάτω όριο και η SELF στο άνω.
3. **`stage1_diagnostics`.** Υπόσχημα (α): καμπύλες $\tau(r)$ ενός γράφου υπό αυξανόμενη απώλεια συνδέσμων· υπόσχημα (β): αποσύνθεση διασποράς του r^* (NCD, PR, POP)· υπόσχημα (γ): μέσο r^* ανά γράφο (POP) έναντι του λανθάνοντος ICC, χρωματισμένο κατά τη διασπορά της ποιότητας· υπόσχημα (δ): κάλυψη χάσματος εκτός δείγματος από τον κανόνα και από τη σταθερά.
4. **`stage2_calibration_scatter`.** Βέλτιστο α^* έναντι του h στο r του Σταδίου 1. Υπόσχημα (α): NCD με τους προσαρμοσμένους υποψήφιους της g (ελάχιστα τετράγωνα, βέλτιστος ως προς $\tau = 0.810$, ισοτονικός, προϋπολογισμός)· υπόσχημα (β): ενωμένες σειρές διαταραχών· υποσχήματα (γ) και (δ): TOT και Q. Οριζόντιες γραμμές σημειώνουν τα 0.85 και 0.95.
5. **`stage2_gt_sensitivity`.** α^* έναντι του h υπό τις πέντε αλήθειες, καθεμία με τη δική της απόσβεση ως οριζόντια γραμμή και τις συσχετίσεις εντός/μεταξύ.
6. **`stage2_diagnostics`.** Υπόσχημα (α): $\tau(\alpha) - \max \tau$ για έναν γράφο (Πείραμα A, διατήρηση του 60% των τόξων) υπό κάθε αλήθεια· υπόσχημα (β): κατανομή του α^* ανά αλήθεια με το δικό α κάθε αλήθειας· υπόσχημα (γ): αποσύνθεση διασποράς του α^*· υπόσχημα (δ): κέρδος πλήρων διαδικασιών έναντι της στατικής ρύθμισης $(0.118, 0.85)$ στο `test` υπό τις NCD, TOT και Q.

10.3 Πίνακες της εργασίας

Πίνακας	Περιεχόμενο	Συνάρτηση παραγωγής
1 `tab:real`	πραγματικά δίκτυα (μέγεθος, μπλοκ, τόξα εντός μπλοκ, μερίδιο κρεμάμενων, $\bar{P}$)	`real_dataset_table`
2 `tab:panels`	σύνολα, γεννήτριες, ρόλοι, γράφοι, στιγμιότυπα, μεγέθη	`panel_table`
3 `tab:stage1`	υποψήφιοι κανόνες Σταδίου 1: CV τ, τ ανά σύνολο, κάλυψη χάσματος, p	`stage1`
4 `tab:stage1dec`	αποσύνθεση διασποράς του r^* ανά αλήθεια	`stage1`
5 `tab:stage2`	υποψήφιοι κανόνες Σταδίου 2 στα h και h_v, διαφορές έναντι της κλειδωμένης σταθεράς	`stage2`
6 `tab:stage2dec`	αποσύνθεση διασποράς του α^* ανά αλήθεια και ρύθμιση r	`stage2`
7 `tab:mixture`	μηχανισμός των Πειραμάτων A και B: δ, ζ, h, h_{raw} από την ηπιότερη έως τη σοβαρότερη στάθμη	`wp0_tables`
8 `tab:nonmono`	μη μονότονοι κανόνες, κανόνες χωρίς την επίδραση των κρεμάμενων σελίδων και κανόνες δύο μεταβλητών για το Στάδιο 2 έναντι της κλειδωμένης σταθεράς	`nonmono`
9 `tab:anchor`	άγκυρες: δικό α, α^* στο A1.0, μέσο α^*, έκπτωση, εντός/μεταξύ	`stage2`
10 `tab:rapr`	δόση–απόκριση: α^* ανά εκ των προτέρων κατανομή Random-α	`stage2`
11 `tab:mismatch`	αντιστοίχιση άγκυρας: υποψήφιο έναντι αναφοράς [NG13] σε όλα τα σύνολα εκτός δείγματος, αλήθειες NCD και NCD95	`mismatch_table`
12 `tab:pipe`	πλήρεις διαδικασίες έναντι στατικών ρυθμίσεων, πέντε αλήθειες × πέντε σύνολα	`pipelines`
13 `tab:conv`	επαναλήψεις της μεθόδου των δυνάμεων και εξοικονόμηση	`convergence`
14 `tab:stage1truth`	το Στάδιο 1 υπό τις τέσσερις αλήθειες του Σταδίου 1 (παράρτημα)	`stage1_truth_table`

Πίνακας	Περιεχόμενο	Συνάρτηση παραγωγής
15 `tab:sens`	κανόνες Σταδίου 2 επαναπροσαρμοσμένοι ανά αλήθεια ευαισθησίας (παράρτημα)	`stage2`
16 `tab:realdetail`	πραγματικά δίκτυα ανά δίκτυο (παράρτημα)	`real_detail`
17 `tab:mixture`	μηχανισμοί μειγμάτων για τα Πειράματα Α και Β	`nonmono_summary`
18 `tab:mismatch`	συγκρίσεις με και χωρίς αντιστοίχιση άγκυρας	`pipelines`

11. Αναπαραγωγή βήμα προς βήμα

Όλες οι εντολές εκτελούνται από τον κατάλογο `ncdcal/`.

1. **Εγκατάσταση**: Python 3.13 και `pip install numpy scipy pandas scikit-learn matplotlib webgraph`· για τα κείμενα, διανομή TeX με XeLaTeX και τη γραμματοσειρά FreeSerif· για αυτή την τεκμηρίωση, pandoc.
2. **Έλεγχοι μονάδας** (λίγα δευτερόλεπτα): `python3 tests/test_lib.py && python3 tests/test_stage2.py && python3 tests/test_nonmono.py && python3 tests/test_autotune.py && python3 check_build.py && python3 verify_v2.py`.
3. **Πρωτογενή δεδομένα** στο `../data/`: τα αρχεία BVGraph του cnr-2000 (`cnr-2000.graph`, `.offsets`, `.properties`) από το Laboratory for Web Algorithmics (https://law.di.unimi.it/webdata/cnr-2000/) στο `../data/cnr2000/`· το αρχείο `dataset/data.json` του https://github.com/pmernyei/wiki-cs-dataset (αποθηκευμένο ως `wikics_data.json`) και τα αρχεία CitationFull `cora.npz`, `cora_ml.npz`, `citeseer.npz` του αποθετηρίου graph2gauss (https://github.com/abojchevski/graph2gauss, αποθηκευμένα ως `g2g_<name>.npz`) στο `../data/other/`.
4. **Αποκωδικοποίηση του cnr-2000**: `python3 decode_cnr2000.py`.
5. **Προετοιμασία των πραγματικών γράφων**: `python3 prepare_real_graphs.py` (γράφει το `data/real/`).
6. **Πειράματα Σταδίου 1**: `bash run_stage1_all.sh` (περίπου 70 λεπτά με δύο διεργασίες).
7. **Ανάλυση Σταδίου 1**: `python3 stage1_analysis.py`, `python3 stage1_decomposition.py`, `python3 stage1_crosstruth.py`, `python3 stage1_tables.py` (προαιρετικά `python3 stage1_feature_probe.py`).
8. **Πειράματα Σταδίου 2**: `bash run_stage2_all.sh` (περίπου 100 λεπτά).
9. **Ανάλυση Σταδίου 2**: `python3 stage2_analysis.py`, `python3 stage2_decomposition.py`, `python3 stage2_rapr_anchor.py`, `python3 stage2_upper_check.py`, `python3 convergence_check.py`, `python3 bound_check.py`, `python3 verify_stage2.py`, `python3 stage2_tables.py` και `python3 stage2_nonmonotone_search.py` (περίπου 8 λεπτά).
10. **Σχήματα**: `python3 generate_figures.py stage1`, `python3 generate_figures.py stage2` και οι ίδιες δύο εντολές με `--lang gr`.
11. **Κείμενα**: το `bash build_papers.sh` εκτελεί το `make_paper_assets.py` και μεταγλωττίζει τα `paper/paper_en.tex` και `paper/paper_gr.tex` με δύο περάσματα XeLaTeX το καθένα.
12. **PDF τεκμηρίωσης**: το `bash build_docs.sh` μετατρέπει και τους δύο οδηγούς Markdown με pandoc και XeLaTeX (κείμενο σε FreeSerif, Latin Modern Math, `-V fontfamily=fontspec` ώστε το προεπιλεγμένο πρότυπο να μη ζητά το πακέτο `lmodern`).

Έλεγχοι. Το `verify_stage2.py` πρέπει να αναπαράγει το μέσο τ κάθε διαδικασίας του Πίνακα 10 και τους ελέγχους Wilcoxon της διαδικασίας δύο σταδίων (οι μέσες διαφορές που τυπώνει σταθμίζουν τα στιγμιότυπα, γι' αυτό στο σύνολο των πραγματικών δικτύων δείχνει $+0.0000$ εκεί όπου ο Πίνακας 10, που σταθμίζει ισότιμα τους γράφους, δείχνει $+0.0017$)· το `bound_check.py` επιβεβαιώνει το φράγμα μετατόπισης· το `stage2_analysis.py` τυπώνει τη μέγιστη απόκλιση του μέσου αθροίσματος εισερχόμενων μεταβάσεων από τη μονάδα (3.3×10^{-16})· το `stage2_nonmonotone_search.py` επιβεβαιώνει ότι τα h, r και το ποσοστό κρεμάμενων σελίδων της αναπαραγωγής ταυτίζονται με τα αποθηκευμένα (μέγιστη απόκλιση 2.2×10^{-16}).

12. Περιορισμοί που πρέπει να λαμβάνονται υπόψη κατά την παράθεση των αποτελεσμάτων

- Οι συνθετικές γεννήτριες είναι του συγγραφέα· η μεταφορά σε άλλες γεννήτριες δεν είναι εγγυημένη.
- Η διαμέριση του cnr-2000 είναι προσέγγιση hosts, και οι γράφοι παραπομπών χρησιμοποιούν θεματικές ετικέτες, όχι hosts.
- Οι κρεμάμενες σελίδες έχουν ομοιόμορφες γραμμές και όχι τον περιορισμό εντός του μπλοκ που προτείνει η εκτεταμένη εργασία για το NCDawareRank.
- Το Στάδιο 1 είναι αγκυρωμένο στο $\alpha_0 = 0.85$· το πλέγμα του Σταδίου 2 σταματά στο 0.99, γεγονός που λογοκρίνει το μαντείο υπό την Q (ο έλεγχος κορυφής δείχνει ότι το βέλτιστο δεν βρίσκεται πέρα από αυτό).
- Αξιολογούνται μόνο συσχετίσεις κατατάξεων έναντι αναφορών που προκύπτουν από μοντέλα· εξωτερικές κρίσεις συνάφειας θα παρείχαν αλήθεια αναφοράς ανεξάρτητη από την απόσβεση.
- Το κέρδος της διαδικασίας δύο σταδίων στα πραγματικά δίκτυα δεν είναι στατιστικά σημαντικό ($p = 0.812$, 2 από 5 γράφους).

13. Αντιστοίχιση με κεφάλαια της διπλωματικής

Κεφάλαιο διπλωματικής	Ενότητες εργασίας	Κώδικας και έξοδοι
Υπόβαθρο: PageRank, NCD, NCDawareRank	1–2	`ncd_calibration_lib.py` §1–3
Στατιστικό του Σταδίου 1	3	`block_escape`, `structural_features`
Στατιστικό και θεωρία του Σταδίου 2	4	`incoming_sums`, `h_statistics`, `bound_check.py`, `tests/test_stage2.py`
Αλγόριθμος και πολυπλοκότητα	5	Ενότητα 6 του οδηγού
Πειραματικός σχεδιασμός	6	`run_experiments.py`, `prepare_real_graphs.py`, γεννήτριες
Αποτελέσματα Σταδίου 1	7	`stage1_*.py`, Σχήματα 1–3, Πίνακες 3, 4, 12
Αποτελέσματα Σταδίου 2	8	`stage2_*.py`, Σχήματα 4–6, Πίνακες 5–11, 13, 14
Συζήτηση και συμπεράσματα	9–10	—